

RAG INDEXING

Corso di metodi e
strumenti per lo
sviluppo di progetti

Corso di laurea magistrale in Ingegneria Informatica –
Indirizzo Artificial Intelligence & Machine Learning

Gaia Assunta Bertolino

Mat. 242590

Mario Saccomanno

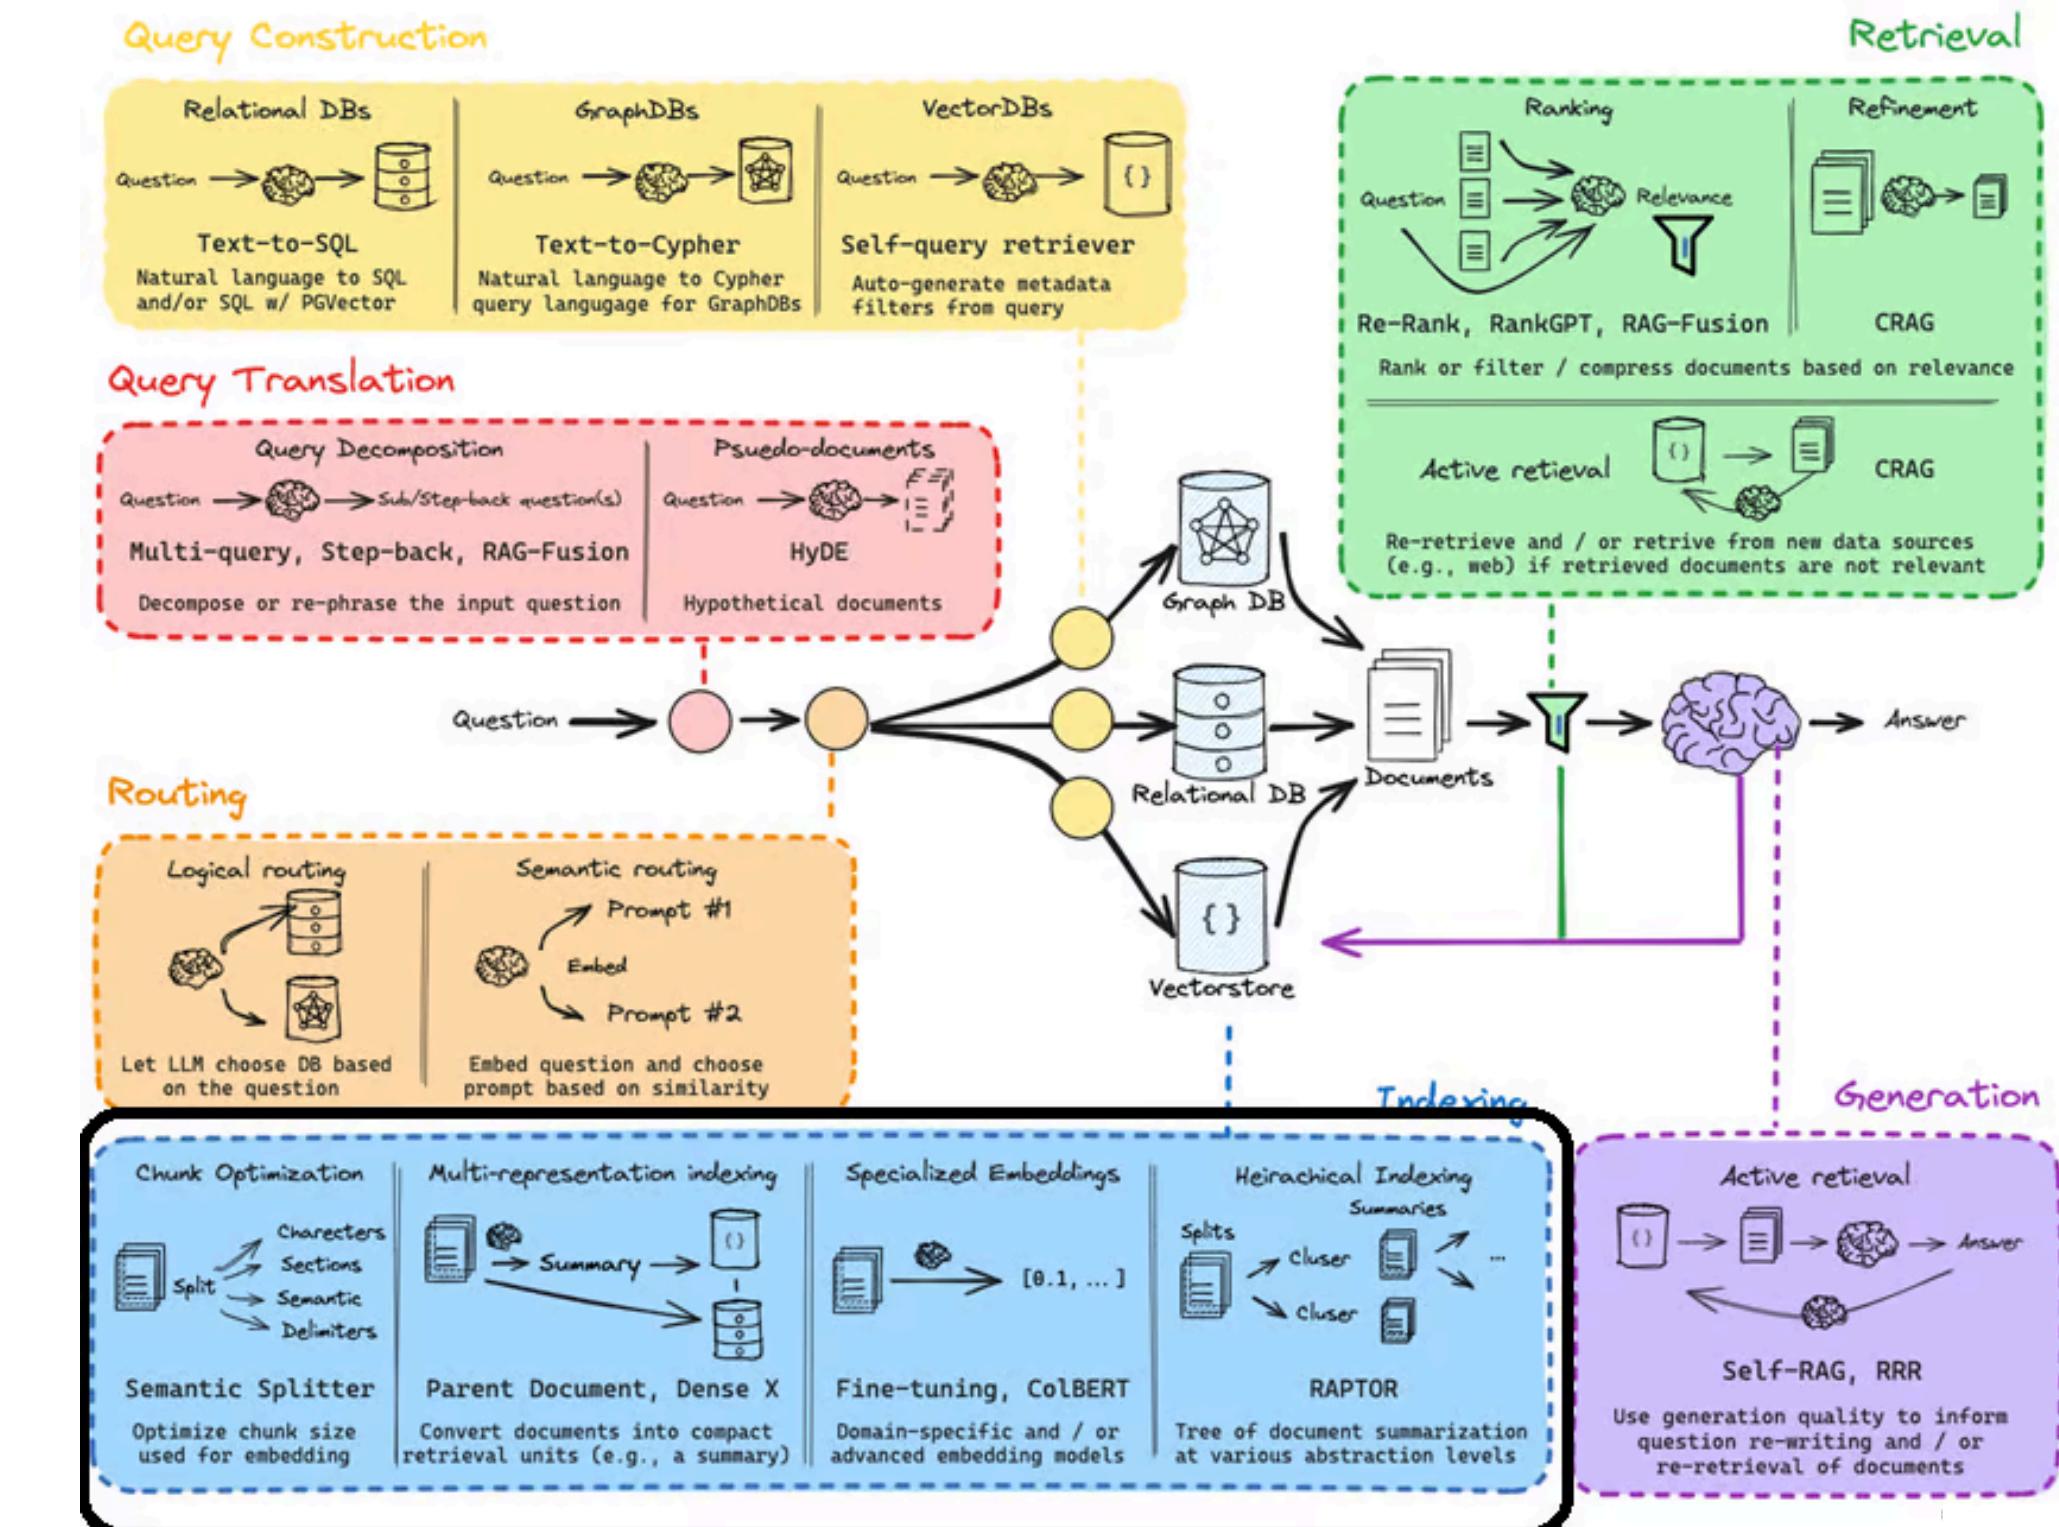
Mat. 248124

Gianluca Ferrari

Mat. 248004

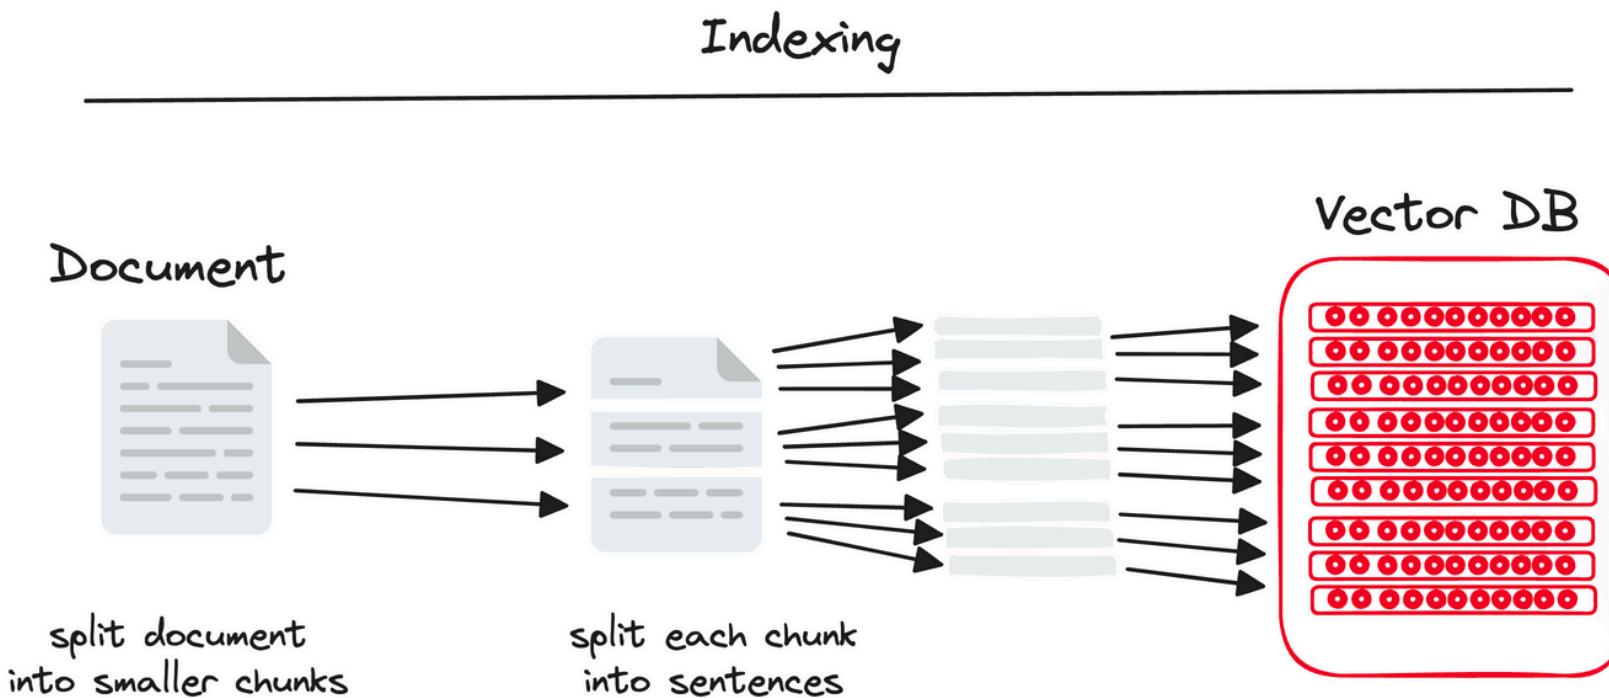


- QUERY CONSTRUCTION
- RETRIEVAL
- QUERY TRANSLATION
- ROUTING
- GENERATION
- INDEXING



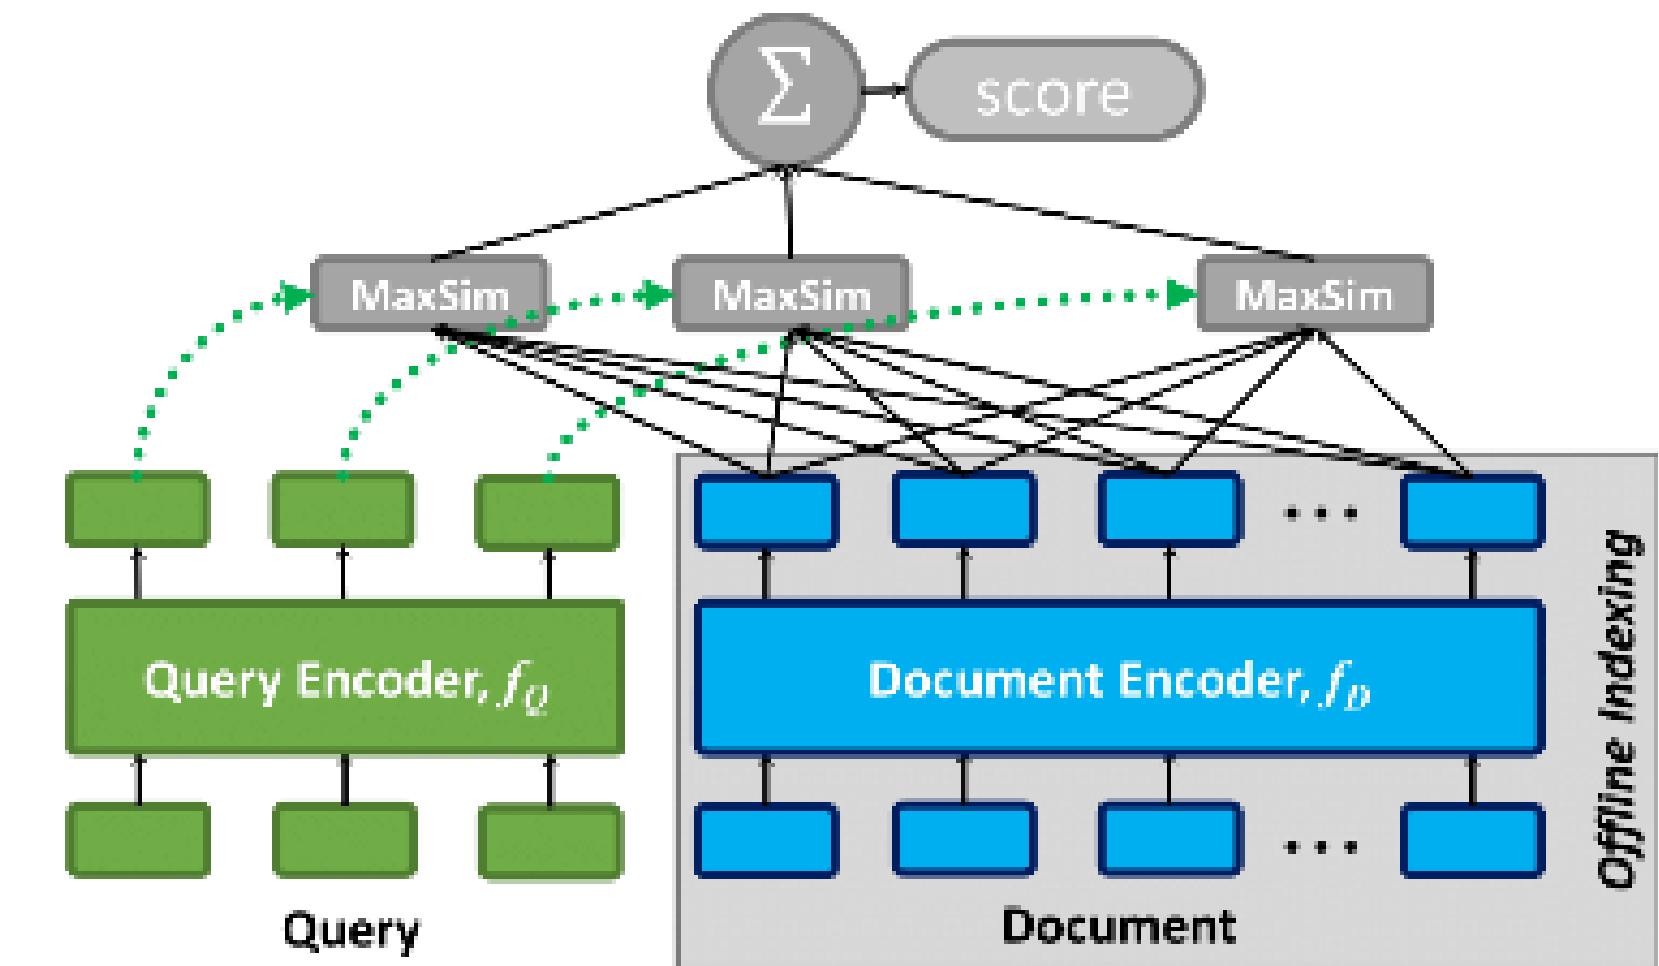
RAG Indexing

- L'indexing consiste nell'**indicizzare opportunamente** i dati. Tale fase è importante per le operazioni di retrieval
- Parti cruciali dell'indexing sono il chuncking e l'embedding
 - Il **chuncking** serve a trasformare una mole di dati in "pezzi" più piccoli, ponendo attenzione alla qualità e al contesto
 - L'**embedding** converte i dati in un insieme di rappresentazioni (vettoriali) che catturano l'essenza dei dati incorporati. Ciò consente il recupero delle informazioni in base alla somiglianza semantica



Specialized Embeddings

- **CoBERT** (Contextual Late Interaction over BERT) è un modello che consente una ricerca scalabile basata su BERT(Bidirection Encoder Representations from Transformers).
- Codifica i dati in una matrice di embeddings. Quando viene eseguita una ricerca, codifica la query dell'utente in un'altra matrice, quindi abbina la query ai pezzi in base al contesto, utilizzando **operatori di similarità vettoriale scalabile** (MaxSim)
- Si parla di **late-stage interaction**: ciò significa che l'interazione tra la query e i documenti avviene in una fase successiva, dopo che i documenti sono stati precomputati



ColBERT Score

- In ColBERT, a differenza della codifica in singolo vettore, ogni token estratto dal testo della query e del documento è **codificato indipendentemente**. Lo score di rilevanza è calcolato come la somma delle massime similarità del coseno tra ogni vettore della query e tutti i vettori nel documento
- Il documento che ottiene lo score di rilevanza più alto per una query ottiene il **ranking** più basso e viceversa
- **CONTRO:** grande mole di dati indicizzati da memorizzare

$$S_{q,d} = \sum_{i=1}^N \max_{j=1}^M Q_i \cdot D_j^T$$

- Q codifica la query con N vettori
- D codifica il testo con M vettori

L'intuizione di questa architettura è allineare ciascun token della query con il token del **passaggio più rilevante** in modo contestuale, quantificare questi abbinamenti e combinare i punteggi parziali attraverso la query

Santhanam, K., Khattab, O., Saad-Falcon, J., Potts, C., & Zaharia, M. (2021, December 2). ColBERTV2: Effective and efficient retrieval via lightweight late interaction. arXiv.org. <https://arxiv.org/abs/2112.01488>

Khattab, O., & Zaharia, M. (2020, April 27). ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. arXiv.org. <https://arxiv.org/abs/2004.12832>

Dataset - document.json

```
1  [
2  {
3      "id": "0025577043f5090cd603c6aea60f26e236195594",
4      "kind": "movie",
5      "text": "<html><title>Pump Up The Volume Transcript</title><pre>\nHappy Hardon - Did you ever get the feeling that everything in America is '",
6      "summary": " Mark Hunter (Slater), a high school student in a sleepy suburb of Phoenix, Arizona, starts an FM pirate radio station that broadcasts",
7      "word_count": 11499
8  },
9  {
10     "id": "014de1a8802c05ff64efa047e9290fb7fccea2b4",
11     "kind": "gutenberg",
12     "text": "\u000ef\u000bb\u000bfThe Project Gutenberg EBook of A Voyage to Arcturus, by David Lindsay\n\nThis eBook is for the use of anyone anywhere at",
13     "summary": " Maskull, a man longing for adventures, accepts an invitation from Krag, an acquaintance of his friend Nightspore, to travel to Tormane",
14     "word_count": 113790
15 },
16 {
17     "id": "019a9611dd8e1b822bd0a58f075cc4a30bdd0797",
18     "kind": "gutenberg",
19     "text": "\u000ef\u000bb\u000bfThe Project Gutenberg EBook of Lisbeth Longfrock, by Hans Aanrud\n\nThis eBook is for the use of anyone anywhere at no",
20     "summary": " The story follows its title heroine, from childhood to confirmation. After her mother's death, Lisbeth (given the nickname Longskirt,
21     "word_count": 41580
22 },
```

- File JSON contiene i testi e i relativi summary e metadata
- Gli ids corrispondono alle domande relative al testo contenute nel file *subsampled_golden_pairs.json*

Dataset - subsampled_golden_pairs.json

```
1  [
2    {
3      "id": "f7bb9eb9306b79cad4b6466f2ac3dcdb0e5fa63a",
4      "question": "Why did Reverend Mother chastise Deloris?",
5      "answers": [
6        "Deloris sneaked off to a bar.",
7        "For drinking in a bar"
8      ],
9      "kind": "movie"
10 },
11 {
12   "id": "2453d062843edc379bdae3be69859e18bf1abd9d",
13   "question": "What does Augustus reveal to Hazel after staying in Amsterdam together?",
14   "answers": [
15     "That his cancer is terminal",
16     "his cancer has relapsed"
17   ],
18   "kind": "movie"
19 }
```

- File JSON contenente 83 domande univoche e rispettive risposte
- Contiene le query e answers di riferimento (ground truth)
- Gli ids corrispondono agli indici dei testi a cui le domande fanno riferimento

Librerie e ulteriori modelli

- **LANGCHAIN**: libreria che semplifica la creazione di applicazioni basate su modelli per processare il linguaggio naturale supportando anche l'**integrazione** con piattaforme come OpenAI e Hugging Face e funzionalità per lo storing in Vector Store
- **RAGATOUILLE**: libreria che facilità l'**integrazione** di ColBERT all'interno della **pipeline di IR**
- **MistralAI/Mixtral-8x7B-Instruct-v0.1**: modello di linguaggio **addestrato per generare risposte** informative e coerenti alle domande degli utenti. Mixtral 8x7B è un modello di lingua di tipo **Sparse Mixture of Experts (SMoE)**, una metodologia di modellazione in cui più "esperti" (modelli individuali) sono combinati insieme e un "gating network" decide quale esperto o quali esperti dovrebbero essere utilizzati per fare una previsione per un dato input. La particolarità è che, invece di coinvolgere tutti gli esperti per ogni previsione, utilizza solo un sottoinsieme; da qui il termine "**sparse**". Questo modello, estensione del Mistral 7B, è caratterizzato da strati composti da 8 blocchi feedforward (esperti). Utilizza una rete di instradamento per una lavorazione dinamica, consentendo a ciascun token di accedere a 47B parametri con **solo 13B parametri attivi** durante l'inferenza

Retrieval step

- Tramite Ragatouille si invoca il modello pre-addestrato ColBERT (v2) da 110M parametri
- Le informazioni passate al modello sono divise in tre arrays:
 - array dei documenti: stringhe composte dal testo e dal summary
 - array degli ids: stringa alfa numerica che viene utilizzata per l'identificazione dei testi
 - array dei metadati: contiene solo l'id numerico generato per il documento

es.

```
[{'content': 'Mary Clarence objects to following the strictures and simple life of the convent, but comes to befriend several of the nu
'score': 18.953125,
'rank': 1,
'document_id': 'f7bb9eb9306b79cad4b6466f2ac3dcbd0e5fa63a',
'passage_id': 34473,
'document_metadata': {'source_id': '46'}},
{'content': 'Deloris convinces Monsignor O\'Hara that the nuns should be going out to clean up the neighborhood. This they do, and the
'score': 18.546875,
'rank': 2,
'document_id': 'f7bb9eb9306b79cad4b6466f2ac3dcbd0e5fa63a',
'passage_id': 34474,
'document_metadata': {'source_id': '46'}},
{'content': "After Deloris walks in on Vince having his chauffeur Ernie executed for betrayal, Vince orders his two henchmen Joey and
'score': 18.328125,
'rank': 3,
'document_id': 'f7bb9eb9306b79cad4b6466f2ac3dcbd0e5fa63a',
'passage_id': 34472,
'document_metadata': {'source_id': '46'}}]
```

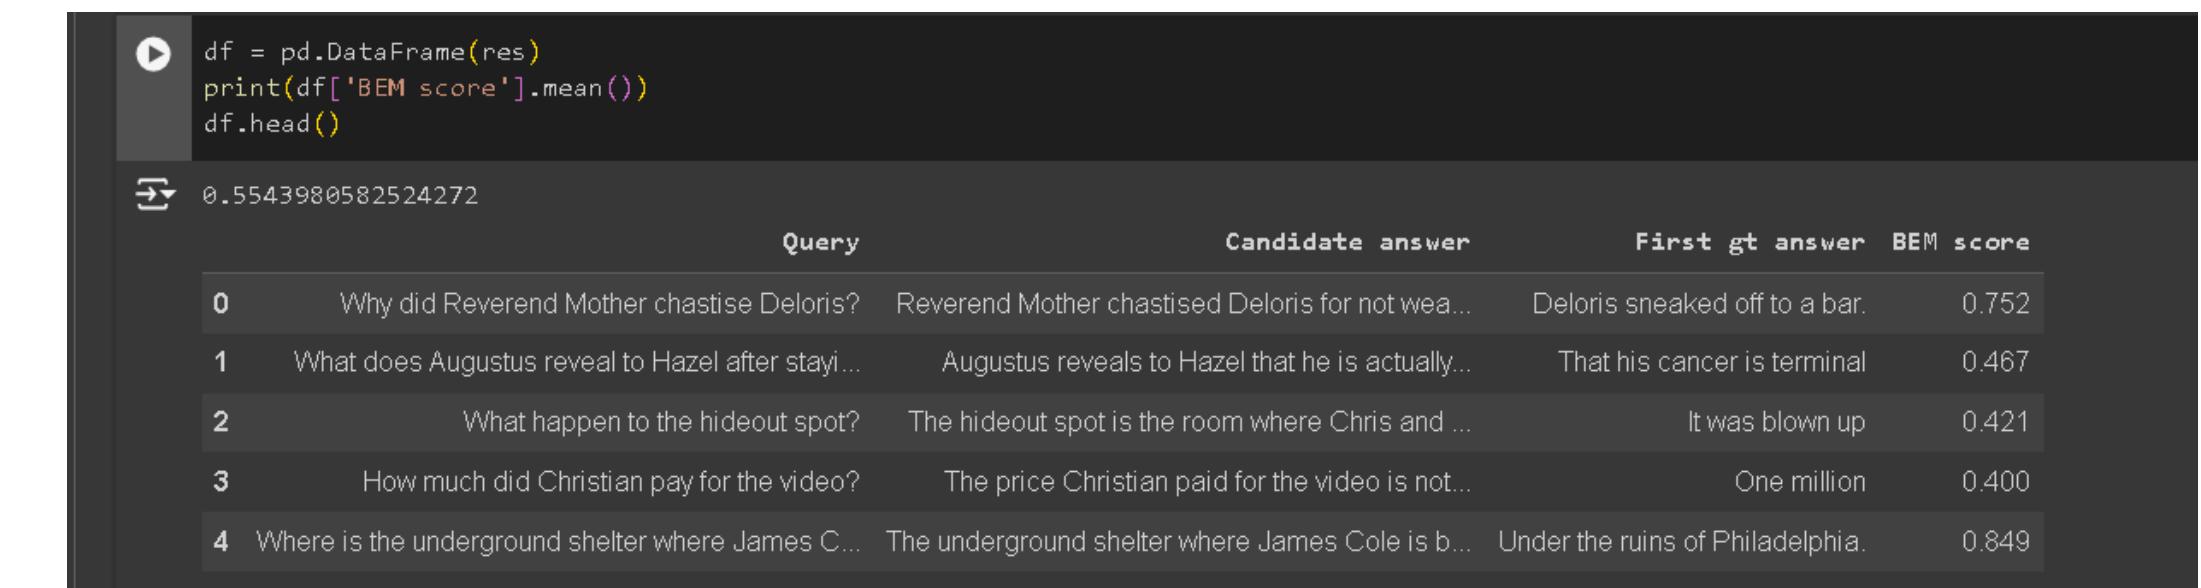
```
# Query example
query = "Why did Reverend Mother chastise Deloris?"
RAG = RAGPretrainedModel.from_index(index_path)
results = RAG.search(query)
```

Generation step ed evaluation

- Viene standardizzato l'input (le queries) da sottoporre al modello come prompt
- Per ogni domanda, il modello genera una risposta e viene calcolata una metrica rispetto a una lista di risposte di riferimento (**golden answers**) utilizzando una funzione per il calcolo del BEM score
- Lo **score Bert Matching (BEM)** usa un modello BERT per svolgere un task di equivalenza tra risposte: il task è risolto addestrando un classificatore che determina se due risposte sono equivalenti attraverso il calcolo di un punteggio di equivalenza. Tra i tre tipi di confronto, si è ricorso all'uso delle sole due risposte (**ground truth e candidata**)

Generation step ed evaluation

BEM score
without ColBERT
indexing:
0.45



The screenshot shows a Jupyter Notebook cell. At the top, there is a play button icon followed by the code:

```
df = pd.DataFrame(res)
print(df['BEM score'].mean())
df.head()
```

Below the code, the output is displayed:

```
0.5543980582524272
```

Then, a table is shown with the following data:

	Query	Candidate answer	First gt answer	BEM score
0	Why did Reverend Mother chastise Deloris?	Reverend Mother chastised Deloris for not wea...	Deloris sneaked off to a bar.	0.752
1	What does Augustus reveal to Hazel after stayi...	Augustus reveals to Hazel that he is actually...	That his cancer is terminal	0.467
2	What happen to the hideout spot?	The hideout spot is the room where Chris and ...	It was blown up	0.421
3	How much did Christian pay for the video?	The price Christian paid for the video is not...	One million	0.400
4	Where is the underground shelter where James C...	The underground shelter where James Cole is b...	Under the ruins of Philadelphia.	0.849

BEM score with
ColBERT
indexing: **0.58**

```
# Computing BEM medium score

bem_scores = res['BEM score']

mean_bem_score = sum(bem_scores) / len(bem_scores)

print(f"BEM score generale: {mean_bem_score}")
```

BEM score generale: 0.5814854368932042

Conclusioni

CONTRO:

- L'indice richiede un **maggior spazio di memoria**
- La creazione dell'indice richiede un **maggior tempo di esecuzione**
 - **4 minuti** circa per l'embedding di base vs **9 minuti** circa tramite ColBERT
- Nessuna integrazione con il **Vector Store**

PRO:

- ColBERT migliora di **13 punti percentuali** la metrica di base
- Crea una rappresentazione che **conserva dettagliatamente le informazioni** (180 token per documento) nonostante non si sia ricorso al **pre-processing**
- Permette un **embedding automatizzato** ed intuitivo tramite le librerie a disposizione